이미지 분위기(mood) 기반 음악 추천

유승주 20212899

2 Summary of questions and results

RQ1. 인물과 배경을 분리하여 가중 평균한 분석이 전체 이미지 단일 분석보다 분위기(mood) 예측에 우수한가?
-> Yes. 분리후 가중합(8:2)방식이 단일 분석보다 우수함
(match_rate 0.67 vs 0.33)

RQ2. 인물 감정 분석 시 YOLOv8(전신) vs MTCNN(얼굴) 중 어느 방식이 분위기(mood) 예측에 우수한가?
-> YOLOv8(전신)이 MTCNN(얼굴)보다 우수함
(match_rate: 0.5 vs 0.29)

RQ3. 배경 분위기(mood) 분석을 위해 CLIP 모델을 finetune하면 성능이 향상되는가?
-> YES. Fine-tuned CLIP이 기본CLIP 보다 우수함

RQ4. 인물/배경 감정 분석 시 최적의 가중합 비율은?
-> 8:2(인물:배경) 비율에서 최고 성능 (match_rate 0.61)

RQ5. 기본 CLIP과 finetuned CLIP, 인물/배경/전체이미지를 어떻게 조합하는 것이 가장 우수한 분위기(mood)예측 결과를 도출하는가?
-> 인물은 기본CLIP, 배경은 finetuned CLIP으로 분석하고 8:2로 가중 평균한 방식이 가장 우수함(match_rate 0.61)

3 Motivation

SNS, 특히 인스타그램에서는 사진을 올릴 때 배경 음악을 설정할 수 있다. 고양이처럼 특정 피사체가 있을 경우 관련 곡을 추천해주기도 하지만, 대부분은 사진 내용과 관계없이 유행하는 노래들이 반복 추천되는 것처럼 보인다.

이러한 문제의식에서 출발한 본 프로젝트는, 사진에 잘 어울리는 노래를 자동으로 추천하는 것을 목표로 한다. 사람은 이미지를 통해 감정을 인식할 때 인물의 표정뿐 아니라 배경의 분위기까지 함께 고려하지만, 기존 이미지 분석 모델은 전체 이미지를 하나의 특징으로 해석하는 경향이 있다.

이에 따라 인물과 배경을 분리해 각자의 mood를 분석하고, 이를 가중 평균하여 보다 정교한 분위기 인식을 시도하였다. 예측된 mood를 기반으로 이미지와 어울리는 노래를 추천하는 서비스를 구현함으로써, 사용자가 사진에 감성적으로 어울리는 음악을 쉽게 선택할 수 있도록 돕고자 했다.

4 Dataset

4.1 RQ1 실험용 이미지 데이터셋

- 이미지 수: 3장

- 구성: 배경과 사람의 분위기가 상반된 이미지

https://drive.google.com/drive/folders/14ZmYrfB8Uu9IiZzGZeLZ_QEHFTVdJd9y?usp=sharing

4.2 RQ2,4,5 실험용 이미지 데이터셋

- 이미지 수: 31장
- 구성: 10가지 감성 태그로 라벨링 된 이미지

https://drive.google.com/drive/folders/106CLtANP_dGKeCsyu9GlsX8kgjxFsSsX?usp=drive_link

4.3 RQ3 학습,실험용 이미지 데이터셋

(colab에서 drive 마운트)

<train Dataset>

- 이미지 수: 111장
- 구성: 10가지 감성 태그로 라벨링 된 '배경'이미지

https://drive.google.com/drive/folders/1obKzdMPidXG5O2ojlinLugzd0ckfn37B?usp=sharing

<test Dataset>

- 이미지 수: 19장
- 구성: 다양한 '배경' 이미지

https://drive.google.com/drive/folders/19dhOVR8c2aNWi2qMRCkhV6R49kDDMQWF?usp=sharing

4.4 감정 기반 음악 데이터셋 (Last.fm API)

https://www.last.fm/api

5 Method

5.1 RQ1. 인물/배경 분리 vs 전체 이미지 mood예측 비교

1) 실험용 이미지 (구글 드라이브1, 3장, Labeled) 다운
2) YOLO로 인물 부분을 crop하여 인물 이미지,
   마스킹으로 해당 부분을 가린 배경 이미지 각각 생성
3) 인물 이미지, 배경 이미지, 전체 이미지 CLIP으로
   10개의 mood 태그에 대해 유사도 계산하여 best_mood추출
4) 인물 유사도와 배경 유사도를 8:2 가중합한 정답률과
   전체 이미지 정답률 비교

5.2 RQ2. 전신(YOLOv8) vs 얼굴(MTCNN) 기반 감정 비교

1) 실험용 이미지 (구글 드라이브2, 31장, Labeled) 다운
2) YOLO와 MTCNN으로 인물 crop하여 각각 인물 이미지 생성
3) 각각 CLIP으로 10개의 mood 태그 유사도 계산하여 best_mood 추출
4) YOLO와 MTCNN 정답률 비교

5.3 RQ3. CLIP 배경 위주 fine-tune 후 기본CLIP과 비교

0) Colab에서 Ipynb파일로 진행
1) 구글 드라이브 마운트 후, 학습용 이미지

(구글 드라이브3, 111장, Labeled),
실험용 이미지 (구글 드라이브3, 19장) 다운
2) 학습용 이미지를 사용해서 CLIP finetune
(text는 고정. 이미지만 finetuning)
3) 실험용 이미지를 사용해서 finetunedCLIP과 기본CLIP mood예측
4) 두 모델 예측 결과 비교
- 예측한 감정이 다를 경우, 이미지와 더 적절해보이는 모델
- 예측 감정이 같을 경우, 더 예측점수가 높은 모델

5.4 RQ4. 인물:배경 가중합 비율 비교

1) 실험용 이미지 (구글 드라이브2, 31장, Labeled) 다운
2) YOLO로 인물 이미지, 배경 이미지 분리
3) 인물,배경 각각 mood 유사도 계산(finetuned 모델사용)
4) 인물이 없는 이미지의 경우 배경이미지 점수만,
인물이 있는 이미지는 인물:배경 가중합 비율을
변경(4:6, 5:5, 7:3...)하며 예측점수가 가장 높은 비율 찾기

5.5 RQ5. 인물과 배경, 전체 각각 모델 최적 조합 찾기

1) 실험용 이미지 (구글 드라이브2, 31장, Labeled) 다운
2) YOLO로 인물 이미지, 배경 이미지 분리
3) 인물 이미지 기본CLIP으로 mood 유사도 계산,
배경 이미지 기본CLIP, FinetunedCLIP모델로 각각 유사도 계산
전체 이미지 기본CLIP, FinetunedCLIP모델로 각각 유사도 계산
4) 인물 유사도, 배경 유사도 가중합 변경하며 정답률
가장 높은 조합 찾기
5) 전체 이미지 2개 중 높은 정답률과 4) 결과 비교

5.6 Mood -> Music 매핑 구현 (Last.fm API 사용)

1) instagram의 url을 입력으로 받아 게시글 이미지들 다운
2) 각 이미지의 mood를 최적의 조합으로 예측함
3) Last.fm의 태그 기반으로 mood와 유사한 음악을
매핑하여 링크와 함께 출력

본 프로젝트는 기존의 CLIP 모델을 사용자 정의 이미지 라벨을 통해 fine-tune한 점(RQ3), 인물/배경 분리를 통한 새로운 분석 파이프라인을 도입한 점(RQ1, RQ2, RQ4, RQ5), 그리고 라벨링된 자체 데이터셋을 활용한 점에서 Challenge Goals에 부합한다. 최종적으로 사용자의 이미지에 감정적으로 어울리는 음악을 추천하는 end-to-end 서비스를 구현함으로써, 감정 기반 콘텐츠 추천의 실질적 가능성을 제시하였다.

6 Results

RQ1. 인물과 배경을 분리하여 가중 평균한 분석이 전체 이미지 단일 분석보다 mood예측에 우수한가?

- 실험은 3장의 배경과 인물이 상반된 이미지를 활용해 happy/gloomy를 예측하였다. 각각 인물과 배경을 분리하고 CLIP으로 mood를 예측한 후 가중

평균(8:2)를 수행하였다.
- 전체 이미지를 CLIP으로 분석한 결과는 match_rate 0.33, 분리 후 가중합한 방식은 0.67
- 해석: 인물과 배경이 상반된 감정을 갖는 경우, 분리하여 해석하고 가중평균하는 방식이 더 정밀하고 사람과 유사한 판단 결과를 도출한다

Figure 1: Combined vs Whole Image

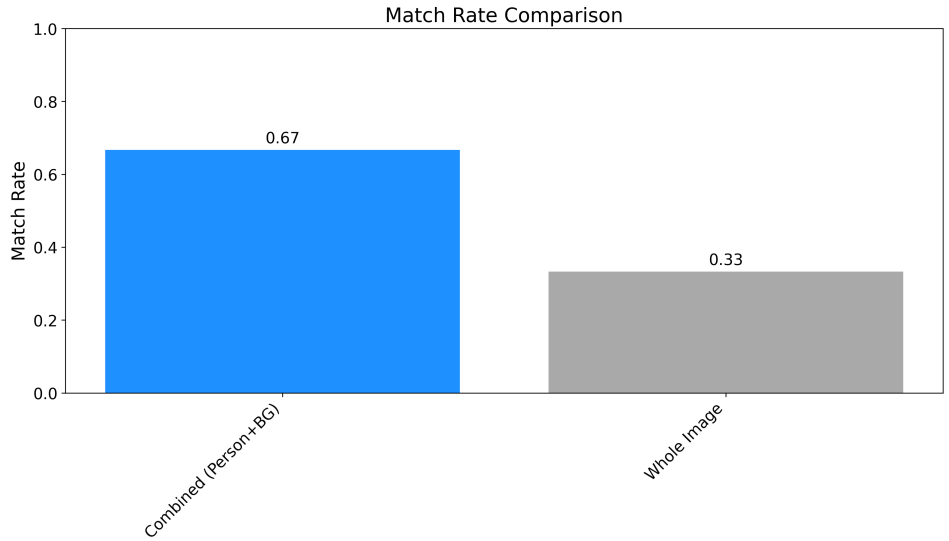

RQ2. 인물 감정 분석 시 YOLOv8(전신) vs MTCNN(얼굴) 중 어느 방식이 mood예측에 우수한가?
- 31장의labeled 이미지에 대해 YOLOv8과 MTCNN으로 각각 인물을 crop하여 CLIP으로 mood 예측 정답률을 비교하였다
- YOLO기반 전신 분석 match_rate는 0.50, MTCNN 기반 얼굴 분석은 0.29
- 해석: 전신 이미지는 표정 외에도 자세, 동작, 의상 등의 맥락 정보를 포기하기 때문에 감정 예측에 더 많은 단서를 제공한다

Figure 2: YOLO vs MTCNN

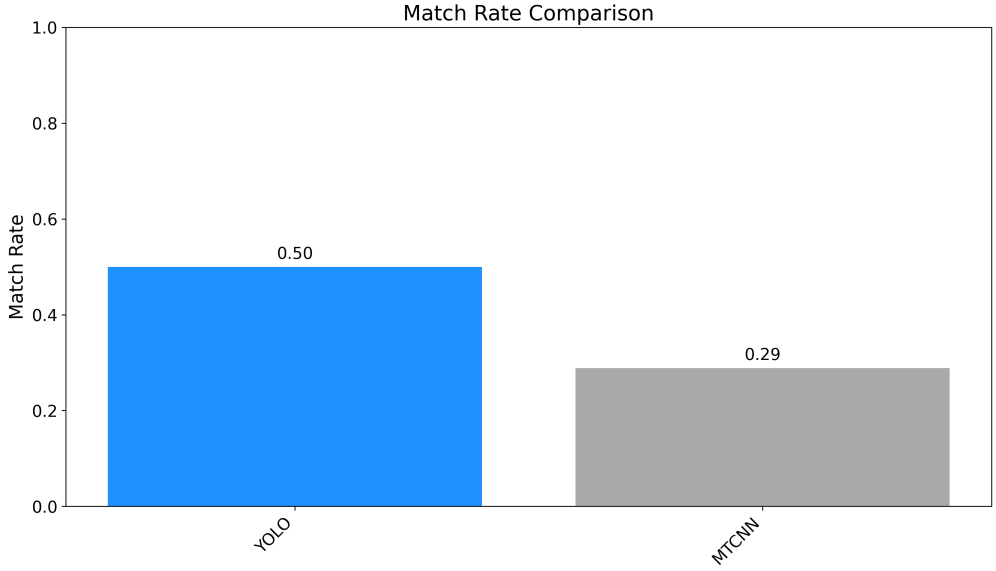

RQ3. 배경 감정 분석을 위해 CLIP 모델을 fine-tune하면 성능이 향상되는가?

- 111장의 학습용 배경 이미지로 CLIP의 이미지 인코더를 finetune하고, 19장의 실험 이미지에 대해 기존 CLIP과 성능 비교한다.
- 감정 예측이 다를 경우, 사람이 보기에 더 적절한 감정을 고른 결과 finetuned CLIP의 판단이 더 적절한 경우가 많았음
- 예측 감정이 같을 경우에도 finetuned CLIP의 정확도가 더 높은 경우가 많았음.
- 해석: 일반 CLIP은 배경의 mood를 잘 반영하지 못하고, finetuning을 통해 더 인간처럼 mood를 예측하게 됨
- Colab에서 Ipynb으로 실행

Figure 3: Finetuned vs Baseline 1

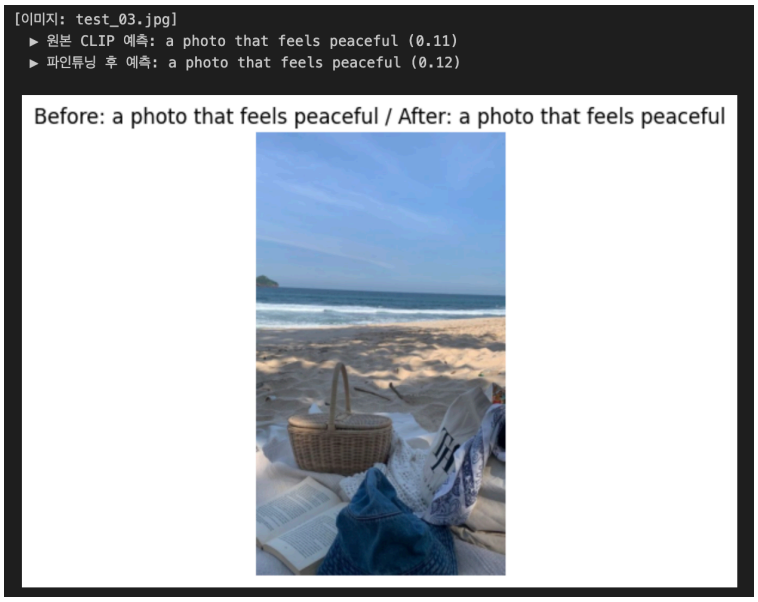

Figure 4: Finetuned vs Baseline 2

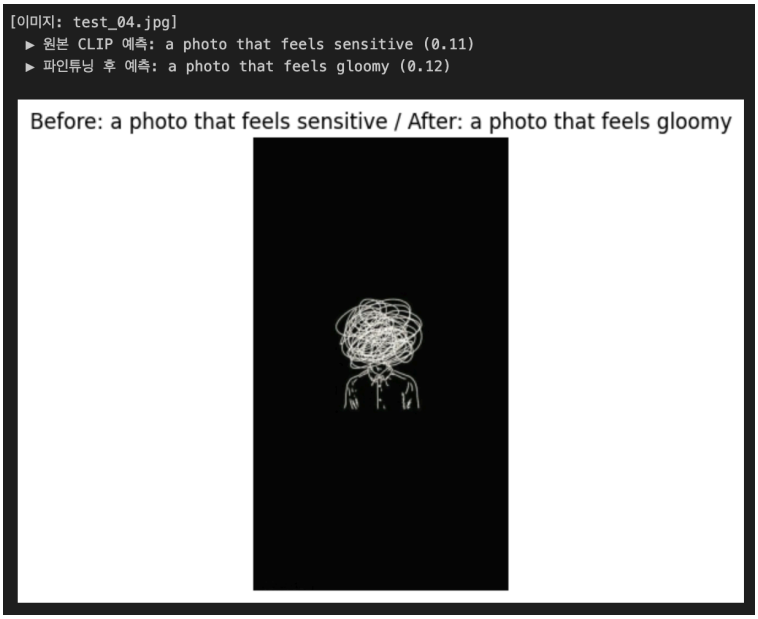

RQ4. 인물/배경 감정 분석 시 최적의 가중합 비율은?

- 31장의 이미지에 대해 인물(CLIP), 배경(finetuned CLIP)의 mood 유사도를 각각 계산하고, 다양한 가중합 비율로 예측 결과를 조합함

Figure 5:비율 별 match_rate

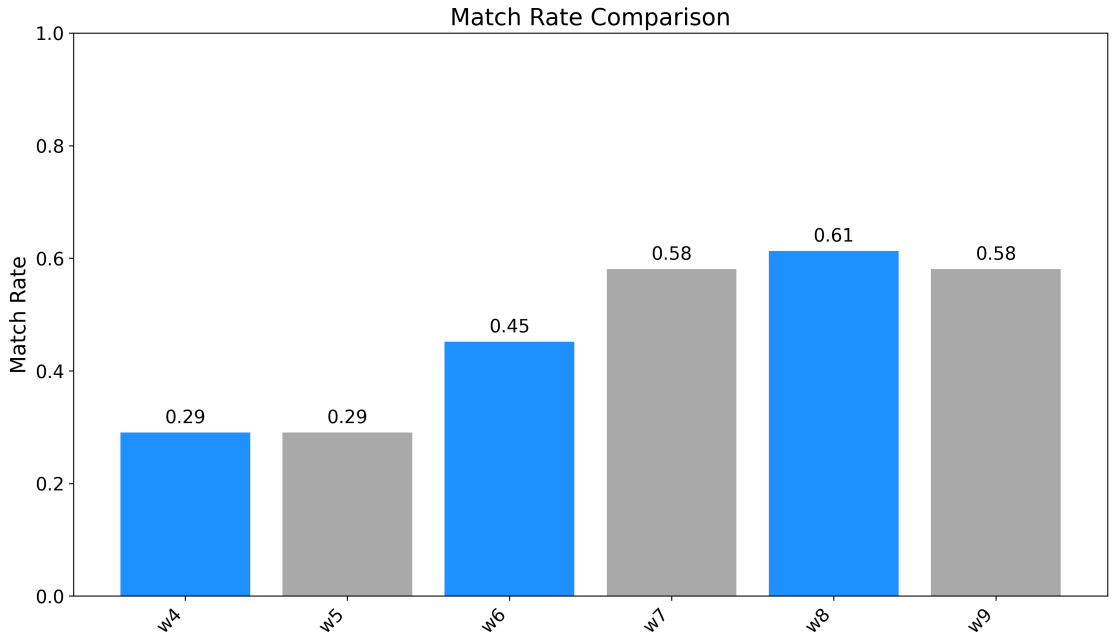


```
[✔] Best match rate: 0.6129 at weight_person=0.8
```

-해석: mood 판단에서 인물이 더 많은영향을 미치지만 배경도 영향이 없진 않음

RQ5. 기본 CLIP과 fine-tuned CLIP, 인물/배경/전체이미지를 어떻게 조합하는 것이 가장 우수한 감정 예측 결과를 도출하는가?

- 인물은 기본 CLIP, 배경은 finetuned CLIP을 사용하여 8:2 비율로 가중합한 방식이 match_rate 0.61으로 가장 우수함.
- 전체 이미지를 기본 CLIP으로 분석한 결과(0.59)보다 명확한 mood 예측을 제공함
- 해석: 인물은 기본 CLIP으로 충분한 성능을 내고, 배경은 finetuning을 통해 더 mood를 잘 예측하며, 이 둘을 조합한 방식이 전체이미지를 기본 CLIP로 예측한 것 보다 우수함.

Figure 6: 최상의 조합 match_rate

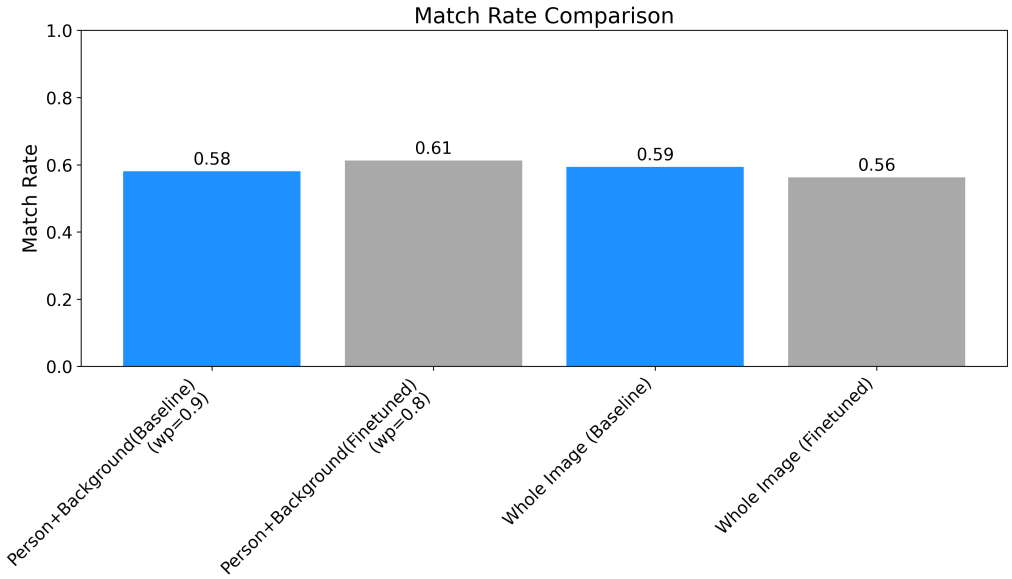

6. 예측한 감정으로 노래 추천하기

- 임의의 인스타 게시글 URL을 입력하면, 이미지들의 mood를 예측함.
- 예측한 mood를 바탕으로 노래 10곡 추천, url 제공
- 해석: 이미지에서 감지를 통해 추출된 감정은 다양한 분위기(peaceful, happy, delicious 등)를 반영하며, 이를 기반으로 한 음악 추천 결과로, 이미지에 어울리는 곡으로 구성되었다.

Figure 7: 예시 게시물과 결과

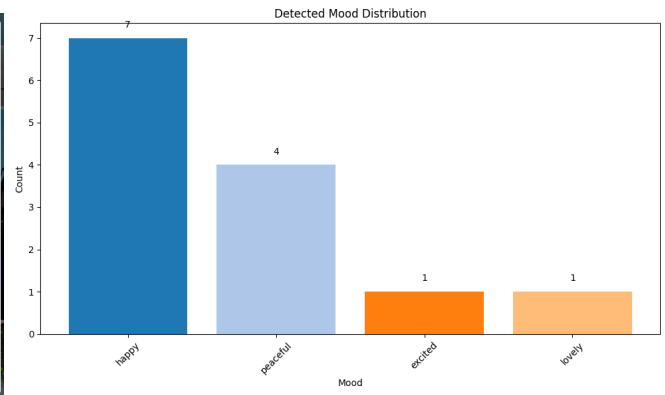


```
mood,tags,track_name,artist,url
happy,bright,Arms Tonite,Mother Mother,https://www.last.fm/music/Mother+Mother/_/Arms+Tonite
happy,bright,Alcohol-Free,TWICE,https://www.last.fm/music/TWICE/_/Alcohol-Free
happy,cheerful,Happy Up Here,Röyksopp,https://www.last.fm/music/R%C3%B6yksopp/_/Happy+Up+Here
happy,cheerful,Heart Out,The 1975,https://www.last.fm/music/The+1975/_/Heart+Out
happy,joyful,The Illest Villains,Madvillain,https://www.last.fm/music/Madvillain/_/The+Illest+Villains
happy,joyful,Nancy From Now On,Father John Misty,https://www.last.fm/music/Father+John+Misty/_/Nancy+From+Now+On
happy,playful,Redbone,Childish Gambino,https://www.last.fm/music/Childish+Gambino/_/Redbone
happy,playful,Don't Stop Me Now - Remastered 2011,Queen,https://www.last.fm/music/Queen/_/Don%27t+Stop+Me+Now+-+Remastered+2011
peaceful,calm,we can't be friends (wait for your love),Ariana Grande,https://www.last.fm/music/Ariana+Grande/_/we+can%27t+be+friends+(wait+for+your+love)
peaceful,instrumental,BIRDS OF A FEATHER,Billie Eilish,https://www.last.fm/music/Billie+Eilish/_/BIRDS+OF+A+FEATHER
```

7 Impact

본 프로젝트는 사람처럼 상황과 맥락을 통합적으로 고려하는 감성 예측 방식을 제안하였다.
이는 다음에 활용할 수 있다.

- SNS 이미지 기반 mood 예측으로 적절한 음악 추천
  (게시글과 함께 올릴 수 있도록)
- 사진 정리, 분류 시스템에서 mood 필터링 기능

다만, 잘못된 판단을 내린다면 사용자에게 불쾌감을 줄 수도 있을 것 같다.

8 Challenge goal

이미지의 mood를 **사람처럼 다각적으로 분석하여 음악 장르를 결정**하는 시스템 구현한다.

이 프로젝트의 핵심은 단순히 CLIP을 통해 감정 키워드와 유사도를 계산하는 것에 그치지 않고, 사람이 이미지를 보고 감정을 해석할 때처럼 다양한 요소(인물, 배경 등)를 종합적으로 고려하여 감정 상태를 추론하고 그에 맞는 음악 장르를 선택하는 과정 전체를 설계한다.

이를 통해 **mood 기반 음악 추천에서 사람다운 판단 방식을 재현하는 것**이 본 프로젝트의 목표이다.

9 Work Plan Evaluation

프로젝트를 진행하면서 구조적으로 두 번 큰 변경이 있었다.
처음에는 아이디어 수준에서만 구상되어 구체적인 작업 흐름이 없었고, 실험(RQ) 간의 연결성과 방향성이 부족했다. 이에 각 RQ를 구현 흐름에 따라 재구성하였다.
두 번째는 교수님과의 면담을 통해 "배경에 emotion이 있다는 개념이 애매하다"는 피드백을 받았고, 그에 따라 감정(emotion) 대신 mood라는 태그를 도입했고, 기존 CLIP이 배경의 mood를 추출하도록 훈련되지 않았을 가능성을 인지하여, CLIP모델을 finetuning하는 실험을 추가하면서 전체 프로젝트의 틀이 크게 바뀌었다.

이로 인해 다음과 같은 예상 외의 시간과 노력이 발생했다:
- finetuning을 위한 이미지 수집 및 라벨링에 많은 시간 소요
- Spotify API로 음악 추천을 구현하려 했으나 권한 문제로 Last.fm API로 전환
- dataset이 google drive에 있어 다운로드를 많이 받다보니 다운로드 제한으로 실험 지연
- 로컬에서는 huggingface 기반 모델, colab에서는 openai 기반 모델을 혼용하다 충돌 발생 -> Huggingface 기반으로 통일하며 많은 시간 소요
- 하나의 파일에서 모든 실험을 하였으나, rq단위로 파일을 나누는 리팩토링 과정에서 많은 시간 소요

따라서 기존 계획과 실제는 다음과 같이 진행되었다.

Table 1: 기존 Work Plan

번호	작업 내용	예상 시간
1	이미지 수집 및 전처리	약 2시간
2	RQ1: 얼굴(MTCNN) vs 전신(YOLOv8) 감정 비교	약 10시간

3	RQ2: 인물/배경 분리 vs 전체 감정 비교	약 10시간
4	Last.fm 기반 감정 -> 음악 매핑 구현	약 3시간
5	RQ3: 다중 이미지 감정 방식 비교	약 15시간
6	RQ4: CLIP외의 모델 비교	약 10시간
7	결과 분석 및 정리	약 4시간

Table 2: 실제 Work Plan

번호	작업 내용	소요 시간
0	흐름 변경으로 기존 작업 제거 및 에러 해결	수 시간
1	이미지 수집 및 라벨링, 전처리	약 8시간
2	RQ1: 인물/배경 분리 vs 전체 비교	약 2시간
3	RQ2: 얼굴(MTCNN) vs 전신(YOLOv8) 비교	약 4시간
4	RQ3: CLIP finetunning 후 비교	약 15시간
5	Last.fm 기반 감정 -> 음악 매핑 구현	약 4시간
6	RQ4: 가중합 비교	약 4시간
6	RQ5: 최적의 조합 찾기	약 3시간
7	결과 분석 및 정리	약 12시간
8	리팩토링	약 15시간

10 Testing

- RQ1,2,4,5의 실험 이미지(구글 드라이브1,2)에는 직접 mood label을 지정하였으며, CLIP이 예측한 'best_mood'와 사람이 지정한 'label'을 비교하여 match_rate를 계산하였다

- RQ3에서는 CLIP finetunig 성능 비교를 위해, 각 mood당 10장 이상의 이미지를 수집하고 사람이 직접 라벨링하여 학습에 사용하였다. 이후 test 이미지에 대해 기존 CLIP과 finetunedCLIP을 모두 적용하여, 사람이 더 나은 결과를 골랐다.

11 Collaboration

- ChatGPT 활용